

Deep Learning Project : Efficient Adaptive Ensembling using MOAT

Dong Uk Shin¹, Kyungseon Lee¹ and Dayeon Jung¹

¹ Department of Statistics, Seoul National University, Seoul, Republic of Korea, {ridaz9980, ppleeqq, jdy5294}@snu.ac.kr

Abstract

최근 이미지 분류 모델의 성능은 일정 수준 이상에 도달하여 SOTA 모델의 경우, 특정 데이터셋에서는 정확도가 99%에 달하는 경우도 있다. 하지만 이런 모델은 정확도가 상당히 높은 만큼 complexity도 높기 때문에 개인이나 모바일 장치에서는 활용하기 어렵다. 따라서 우리는 parameter 수와 연산량(FLOPs)을 기준으로 complexity가 낮은 tiny-MOAT와 증가하는 복잡도를 제한할 수 있는 앙상블 모델인 Effective Adaptive Ensembling을 결합한다. 이 방식은 두 모델의 장점을 모두 가지기 때문에 우리는 complexity가 낮으면서 정확도는 높은 Efficient Adaptive Ensembling using MOAT를 제안한다. 그런 다음 [1]에 쓰인 여러 가지 벤치마크 데이터를 이용하여 우리 모델과 SOTA, Efficient Adaptive Ensembling, MOAT를 비교한다. SOTA model에 비해 우리가 제안한 모델의 성능은 비슷하거나 조금 떨어지지만 복잡도 측면에서 훨씬 줄어들어 범용성을 높일 수 있다. 또한 단일 tiny-MOAT에 비해 높은 정확도를 보이면서도 학습 속도가 줄어들었으며 Efficient Adaptive Ensembling에 비해 정확도는 조금 떨어지지만 EfficientNet의 단점을 해결할 수 있다는 점에서 의의가 있다.

Keywords— MOAT, Ensemble, Self-attention, Transformer

I. INTRODUCTION

1.1 Moat

자연어 처리 분야에서 이미 성공을 거둔 "Self-attention[5] 기반의 Transformer"는 요즘 Computer vision 분야에서도 많이 적용되고 있으며 성능 부분에서 특히 강세를 보이고 있다. MOAT [6]는 이 두 방법과 전통적인 Convolution Neural Network(CNN)의 장점을 결합한 이미지 분류 방법으로서 높은 효율성과 강한 capacity를 보이는 특징이 있다. 따라서 우리는 이 MOAT의 채널 수를 줄여서 단순화한 tiny-MOAT를 앙상블하여 너무 복잡하지 않고 누구나 쉽게 접근할 수 있으면서 정확도도 뛰어난 모델을 만들고자 했다.

Self-attention[5]이란 input vector에 상황을 설명하는 weight를 부여하는 인코더라고 볼 수 있다. 자연어 처리에서는 input vector로부터 queries, keys, values 세 가지 벡터를 만들고 특정 위치의 단어가 다른 단어와 얼마나 연관되어있는지, 즉 문맥적 관계성을 weight로 추출하고 이용한다. 이러한 Self-attention을 image 분석에도 사용하기 위한 시도가 있었으나 쉽지 않았다. 하지만 기존의 제한적인 attention 적용에서 벗어나 CNN 구조를 Transformer로 대체하는 방법이 제기되면서 vision 분야에서도 Self-attention transformer model이 강세를 보이기 시작했다. Vision transformer(ViT)[2]는 이미지를 patch로 분할한 후 다시 sequence로 입력한다. 이 방법은 NLP와 input의 형식이 같아지므로 NLP transformer를 이용할 수 있다. 큰 데이터셋을 사전학습하고 작은 task에서 fine-tuning하는 단계로 학습을 진행한다. 장점으로는 모델의 크기가 커질수록 성능이 더 높아지므로 성능 포화에 대한 걱정이 없다. 대신 큰 데이터셋을 이용하지 않으면 다른 방법론들보다 성능이 떨어지는 단점이 있다. 하지만 ImageNet 이상의 큰 데이터셋을 구하기는 쉽지 않고 구하더라도 모델을 돌리는 데에 필요한 GPU도 매우 크

기 때문에 개인이 모델을 이용하거나 pre-train하기에는 한계점이 분명하다. 이러한 문제를 해결하기 위해 google 등의 대기업에서 제공하는 pre-trained weight를 이용하는 것도 한 가지 방법이다.

MOAT의 구조에 대해 더 자세히 설명하자면 Transformer 방법을 결합하기 위해 ViT[2]의 방식을 차용하지만, 적은 이미지로 훈련했을 때 낮은 성능이 나오는 ViT의 단점을 줄이기 위해 전통적인 ConvNet의 계층 구조인 Mobile Convolution block(MBConv blocks)를 같이 채택한다. 이 block들은 각각 Figure 1의 (a)와 (b)에 구조가 나타나 있다.




Fig. 1. 왼쪽부터 순서대로 MBConv Block, Transformer block, MOAT block의 구조
Source:[6]

MOAT 논문[6]에서는 두 블록을 효과적으로 합치기 위해 매우 단순한 방법을 사용하는데, Figure 1을 보면 MOAT 블록을 어떻게 구성했는지 알 수 있다. Transformer에서 MLP 부분을 MBConv로 대체한 후, Self-attention layer와 MBConv의 순서를 바꾸었다. 이렇게 만들어진 block을 MOAT라 하고 MOAT의 채널을 줄인 block을 tiny-MOAT라고 한다. MOAT는 구조의 일부를 합치는 단순한 방식으로 만들어진 모델이지만 정확도에 있어서 매우 좋은 결과를 보여주고 있다.

1.2 Ensembling

이미지 분류를 위한 최초의 neural network가 등장한 이후로 많은 시간이 지나면서 CNN[3]기반의 분류기는 점점 높은 정확도를 달성했다. 일정 이상의 정확도를 달성하고나서 최근 새로운 방법론의 등장보다는 기존의 방법론들의 ensemble이 주요한 흐름이 되고 있다. 하지만 ensemble은 조금의 성능 향상을 위해 훨씬 더 큰 복잡도와 훈련 시간의 증가를 감안해야한다는 단점이 있다. 복잡도가 커질 수록 개인이 접근하기 어려워지기 때문에 이러한 단점을 극복하면서도 ensemble을 할 수 있는 방법에 대한 수요가 늘어나고 있다.

Efficient Adaptive Ensembling[1]은 효과적으로 이러

Model	Year	Accuracy	Parameters	FLOPs
AlexNet [1]	2012	63.3%	≈ 60M	≈ 0.7G
InceptionV3 [2]	2015	78.8%	≈ 24M	≈ 6G
ResNeXt-101 64x4 [3]	2016	80.9%	≈ 84M	≈ 16G
EfficientNet-b0 [4]	2019	77.1%	≈ 5.3M	≈ 0.4G
EfficientNet-b7 [4]	2019	84.3%	≈ 67M	≈ 37G
Swin-L [5]	2021	87.3%	≈ 197M	≈ 103G
NFNet-F4+ [6]	2021	89.2%	≈ 527M	≈ 215G
ViT-G/14 [7]	2021	90.45%	≈ 1843M	≈ 965G
CoAtNet-7 [8]	2021	90.88%	≈ 2440M	≈ 2586G

Fig. 2. 2012 ~ 2021 이미지 분류 모델들의 늘어난 복잡도
Source:[1]

한 단점을 보완한다. 논문에서 사용된 EfficientNet[4] 모델은 *compound scaling* 기법을 사용한다. 이 기법은 모델이 사용할 수 있는 resource의 양을 나타내는 compound coefficient ϕ 를 도입해 아래의 방정식 규칙에 따라 최적의 scaling 조합을 찾아 최종 복잡도를 2^ϕ 에 비례하게 한다. 이러한 제약조건으로 인해 EfficientNet은 ensemble model이면서 낮은 complexity를 가질 수 있다.

$$\text{depth: } d = \alpha^\phi \quad \text{width: } w = \beta^\phi \quad \text{resolution: } r = \gamma^\phi \quad (1)$$

$$\text{such that } \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \text{ and } \alpha \geq 1, \beta \geq 1, \gamma \geq 1 \quad (2)$$




Fig. 3. Ensemble by votingSource:[1]




Fig. 4. Effective Adaptive Ensembling의 구조Source:[1]

일반적인 앙상블에서는 Figure 3과 같이 각각 weak learner를 학습시킨 후, 가장 많이 나온 output을 선택하거나(분류) 나온 output들의 평균을 계산(회귀)하는 것이 보편적이다. Efficient Adaptive Ensembling[1]에서는 일

종의 stacking을 이용하는데, 간략한 절차는 다음과 같다. 먼저 data-set을 겹치지 않는 2개의 세트로 분할한 후, 2개의 분류기를 각 data-set에 충분히 과적합 될 때까지 학습시킨다. 다음으로 각 모델의 output layer를 제거한 두 feature extractor 부분을 input으로 받는 combination layer를 구성하여 최종 모델을 구성한다. Combination layer는 각 모델의 output layer와 같은 형식으로 되어있다. 이 방식은 Figure 4에 자세히 나와있으며 각 model의 representation을 감소시키지 않으면서 ensemble model의 complexity를 감소시킬 수 있다.

1.3 Outline

이 연구는 Main Framework에서 tiny-MOAT와 Efficient Adaptive Ensembling의 결합 구조와 모형 평가 방식을 설명한다. Experiment에서는 Oxford-IIIT Pet data-set, CIFAR-10 data-set, Flowers data-set 세 가지 유명한 data-set들을 이용하여 이미지 분류 실험을 진행한다. 이 실험을 통해 SOTA model, 단일 tiny-MOAT model 그리고 Efficient Adaptive Ensembling보다 개선된 점을 확인할 수 있다. 마지막으로 Future Work에서 앞으로 이 모형을 어떻게 활용할 수 있을지를 논의한다.

II. MAIN FRAMEWORK

2.1 Methods for Ensembling Tiny Moat

본 연구에서 tiny-MOAT를 이용한 Efficient Adaptive Ensembling을 시행한 절차는 다음과 같다. 먼저 학습에 사용된 데이터 세트의 경우에 [1]에서 제안한 방법과 동일하게 전체 학습 데이터 세트를 겹치지 않는 2개 데이터 세트로 분할하는데, 그 전에 우리는 학습 데이터에서 30%를 validation 데이터 세트로 지정하고 그 후 나머지 학습데이터의 70%를 겹치지 않는 두 데이터 세트로 분할하였다. 따라서 두 weak learner(우리의 learner 종류는 classifier이므로 이후 weak learner와 weak classifier 표현을 혼용하여 사용한다.)를 학습할 때 공통의 validation 데이터 세트가 사용된다. Test 과정은 공식적인 test용으로 제공하는 데이터 세트를 사용하여 정확도를 계산하였다. 또한 ViT 계열 모형의 경우, 대용량 데이터로 학습 시 더 뛰어난 성능을 보임이 알려져 있으므로 충분한 데이터 세트의 확보를 위하여 Oxford-IIIT Pet 데이터에 한하여 data augmentation을 시행하였다. Data augmentation 방식으로는 분할된 학습 데이터 세트를 명도와 채도를 조절하여 데이터 세트의 이미지 개수를 4배로 증가시키는 방법을 채택하였다.




Fig. 5. Oxford-IIIT Pet Data 에서 Augmentation을 시행한 모습 : 왼쪽 위부터 원본, 채도 조정, 밝기 조정, 흑백 사진

[1]에서는 weak classifier를 효과적으로 학습시키기 위하여 ImageNet 데이터 세트에서 사전학습된 weight로 전이학습(transfer learning)을 시행한다. 이 방식에 영감을 받아, 우리는 먼저 tiny-MOAT를 전이학습 시키기 위해 ImageNet 데이터 세트로 사전 학습된 MOAT용 weight를 이용한다.(이 weight는 [6]에서 제공하고 있다.) 이때, [1]에서 제안한 과정대로 각 weak classifier의 정확도가 1에 수렴할 때까지 과적합시켰다. 사전 학습된 weight를 입력한 후, soft-max activation이 적용된 말단 층의 unit을 각 데이터 세트에 맞게 조절하였으며 초기값으로는 He-normal 값을 이용하였다. Optimizer는 [1]에서 사용한 것과 동일한 Adabelief를 사용하였다.

과적합 단계를 마치면 학습된 두 tiny-MOAT의 말단부인 fully connected layer를 제거한다. 이 layer를 제거하면서 얻은 두 feature extractor가 input으로 들어갈 combination layer가 필요한데, 일반화된 성능을 얻기 위하여 배치 정규화를 적용하고 combination layer를 연결하여 최종 모형을 구성하였다. 다만 [1]에서 구체적인 형태의 combination layer를 설명하지 않았기 때문에 우리가 직접 여러 형태의 combination layer를 구성하여 실험했다. 그 결과, 두 feature extractor의 말단부를 flatten 하여 한 층의 soft-max activation이 적용된 output에 직접 연결하는 단순한 layer 구성에서 성능이 가장 좋았다. 이를 확인해보니, 깊게 층을 쌓을수록 train loss의 감소 속도는 빨라지지만 최종적인 validation loss의 경우 하나의 층만 쌓은 경우와 차이가 없었다. 따라서 이러한 단층 combination layer로 모든 experiment의 모형을 구성하였다. 최종 모형 학습시 각 tiny-MOAT의 feature extractor 부분은 동결시킨 후 combination layer를 70%의 학습 데이터(두 weak learner의 train set 두 개를 합친 data-set)를 이용하여 학습

시켰다. 특히 Oxford-IIIT Pet Data의 경우 최대의 성능을 끌어내기 위하여 Cosine annealing을 이용하여 step size에 변화를 주었다. 또한 과적합이 필요했던 weak learner 학습 단계와 다르게 과적합을 방지하기 위하여 validation loss가 일정 epoch 동안 감소하지 않으면 조기에 중단하는 early stopping을 사용하였다.

learning rate	beta1	beta2	weight decay	eps
1e-5	0.9	0.999	0.05	1e-14
cosine/1e-5	0.9	0.999	0.05	1e-14

Table 1. 각 단계별로 사용된 Adabelief의 파라미터 : 위쪽부터 과적합 단계, 앙상블 단계

2.2 Model Assessment

[1]에서는 적은 파라미터 수를 가지는 EfficientNet으로 만들어진 ensemble model을 Oxford-IIIT Pet, CIFAR-10 data-set 등으로 실험하고 기존의 SOTA(state-of-the-art) 모델과 비교하였다. 따라서 본 연구는 [1]가 제안한 앙상블 방법이 EfficientNet 뿐만 아니라 EfficientNet의 단점을 상쇄하는 tiny-MOAT에서도 효과적인지 검증하기 위하여 [1]에서 사용한 data-set들의 일부를 이용한 실험을 진행하고 [1]에서 제안한 모델 및 기존의 다른 모델들과 우리가 제안한 모델(Efficient Adaptive Ensembling using MOAT)을 비교한다. 또한 [1]에서 제안한 학습 방법이 tiny-MOAT의 훈련에 효과적이었는지 검증하기 위해 flower data-set을 이용하여 단일 tiny-MOAT model을 학습시킨 후, ensemble model과 성능을 비교하였다. 단일 model은 과적합 단계에서 사용한 하나의 tiny-MOAT를 사용하기 때문에 데이터 분할 없이 전체 데이터 세트를 이용하여 학습시켰다. 그 외의 optimizer의 파라미터나 과적합 방지를 위한 early stopping은 ensemble model의 실험과 동일하게 진행하였다.

위에서 설명한 두 비교를 위해서 구체적인 평가 지표로는 [1]에서 사용한 방법과 동일하게 정확도(Accuracy), FLOPs, 파라미터 수를 사용하였다. 실험 프로그래밍 언어는 파이썬으로 진행했으며 딥러닝 모델은 tensorflow 오픈 소스 머신러닝 Framework를 사용하여 구현했다.

III. EXPERIMENT

3.1 Dataset

Main framework에서 제시한 모델 (Efficient Adaptive Ensembling using MOAT)의 성능을 평가하기 위해 총 3개의 dataset을 이용한다. 전체 데이터셋을 train1, train2,

validation, test 4개 group으로 분리한 뒤, MOAT 학습시에는 train1과 train2 각각을 사용하고 그 후 combination layer 학습과 ensemble model 학습 단계에서는 train1과 train2를 합친 train set을 사용한다. validation set과 test set은 MOAT 모델과 ensemble model 둘 다 동일하다. 각 데이터셋에 대한 자세한 분리 방법은 다음과 같다.

• Oxford-IIIT Pet Data-set

개와 고양이 품종에 따른 총 37개의 클래스로 되어 있으며, 각 클래스 별로 약 200개의 500x500 컬러 이미지를 가져 총 7349개의 컬러 이미지로 구성된다. 이 약 50%는 훈련 (train) 이미지, 나머지 50%는 테스트 (test) 이미지이다. train을 train1 : train2 : validation = 35 : 35 : 30의 비율로 나누어서 사용한다.

• CIFAR-10 Data-set

Airplane, automobile, bird, cat, deer, dog, frog, horse, ship, truck의 총 10개의 클래스로 되어있으며 각 클래스당 6000개 총 60000개의 32x32 컬러 이미지로 구성된다. 이 중 50000개는 훈련 이미지, 10000개는 테스트 이미지이다. train을 train1 : train2 : validation = 42 : 42 : 16의 비율로 나누어서 사용한다. 이미지 resolution은 256x256으로 변환하여 사용한다.

• Flower Data-set

5개의 클래스를 가지고 클래스별 사진의 개수가 다른 꽃 사진 데이터 세트이다. daisy, dandelion, roses, sunflowers, tulips는 각각 633, 898, 641, 699, 799개의 이미지를 가지며 총 3670개의 컬러 이미지로 구성된다. 전부 train 이미지로만 구성되어 있으며 이를 각각 train1 : train2 : validation : test = 4:4:1:1의 비율로 나누어서 각각 1468, 1468, 367, 367 개의 이미지를 이용한다. 이미지 resolution은 256x256으로 변환하여 사용한다.




dog (1)



dog (1)

Fig. 6. Oxford-IIIT Pet Data-set 이미지 예시



horse (7)



ship (8)

Fig. 7. CIFAR-10 Data-set 이미지 예시



tulips (2)



sunflowers (3)

Fig. 8. Flower Data-set 이미지 예시

3.2 Result

• Oxford-IIIT Pet Data-set

해당 데이터셋은 기존 SOTA에서 accuracy가 약 97%, 모델의 parameter 수는 약 480M, FLOPs는 약 299G였다. 우리가 제안한 tiny-MOAT ensemble 모델에서는 accuracy가 약 91%, parameter수가 약 17M, FLOPs는 약 19.6G로 나왔다. 이를 통해 기존 SOTA 모델보다 정확도는 약간 떨어지지만 parameter와 FLOPs가 눈에 띄게 줄어 훨씬 가볍고 빠른 모델임을 확인하였다. 또한 [1]에서 제시한 결과인 Efficient Adaptive Ensembling보다는 성능이 약간 떨어지지만 Conclusion에 제시된 EfficientNet 자체의 단점을 감안했을 때 tiny-MOAT을 이용한 ensemble model이 충분히 가치가 있음을 알 수 있다.

	Accuracy	parameters	FLOPs
기존 SOTA	97.10%	$\approx 480M$	299G
Efficient ensemble	98.22%	$\approx 11M$	0.9G
tiny-MOAT ensemble	91.11%	$\approx 17M$	19.6G

Table 2. Oxford-IIIT Pet 결과

• CIFAR-10 Data-set

해당 데이터셋은 기존 SOTA에서 accuracy가 약 99.5%, 모델의 parameter 수는 약 632M, FLOPs는 약 916G였다. 우리가 제안한 tiny-MOAT ensemble 모델에서는 accuracy가 약 96.78%, parameter수가 약 11M, FLOPs는 약 4.9G로 나왔다. 이전 Oxford-IIIT Pet 데이터셋과 마찬가지로의 결과를 가지며, 다른 데

이터넷에서도 tiny-MOAT ensemble model의 성능이 비슷함을 확인하였다.

	Accuracy	parameters	FLOPs
기존 SOTA	99.50%	$\approx 632M$	916G
Efficient ensemble	99.61%	$\approx 11M$	0.9G
tiny-MOAT ensemble	96.78%	$\approx 11M$	4.9G

Table 3. CIFAR-10 결과

• Flower Data-set

추가로 tiny-MOAT 모형의 앙상블 전후 차이를 알아보기 위해 비교적 데이터 크기가 작은 flowers dataset을 이용했다. tiny-MOAT로 단일 train set을 훈련시킨 결과 accuracy는 약 92.64%였고, 각 train1, train2을 tiny-MOAT 모델에 과적합 시킨 후 앙상블을 통해 얻은 accuracy는 약 95.64%였다. 이를 통해 tiny-MOAT에 [1]의 앙상블 기법을 적용하면 정확도가 향상함을 확인할 수 있었다.

IV. CONCLUSION

4.1 Summary

본 연구는 [6]에서 제시한 tiny-MOAT와 [1]에서 제시한 Efficient Adaptive Ensembling을 합쳐 tiny-MOAT만큼 성능이 비슷하면서 기존 SOTA에 비해 적은 parameter 수와 낮은 복잡도를 가진 새로운 모델을 제시한다. tiny-MOAT는 self-attention 기반 transformer와 CNN을 결합해 최적의 장점을 낸 MOAT 모델 중 비교적 parameter 수가 작은 모델이다. Ensemble 방법은 Figure 4의 방법과 동일하게 진행하였다. Oxford-IIIT Pet dataset, CIFAR-10 dataset, Flowers dataset 총 3가지 데이터셋을 이용하여 제시된 모델에 대한 성능을 accuracy, parameter 수, FLOPs (연산량) 3가지 기준을 통해 평가했고 이를 기존 모델들과 비교해보았다.

기존 SOTA에 나와있는 모델들은 정확도가 매우 높은 반면 그에 비례하게 연산량 및 parameter 수도 상당히 크다는 단점이 있다. Result에 의하면 tiny-MOAT ensemble 모델은 SOTA에 비해 정확도는 약간 떨어지지만 parameter수와 연산량을 10분의 1보다 작은 값으로 획기적으로 감소시켰다. 단일 tiny-MOAT 모델과 tiny-MOAT ensemble 모델을 비교할 경우 ensemble 모델은 2개의 tiny-MOAT를 앙상블 한 model이므로 연산량 및 parameter 개수는 증가하지만, 각 tiny-MOAT 학습 시 데이터셋을 두 개로 분할하여 학습시키기 때문에 각각의 tiny-MOAT 학습 시간은 단일 tiny-MOAT보다 짧다. 또한 데이터셋을 2

개로 분할하는 방법이 매우 단순하다는 점, 추가적인 데이터셋이 필요하지 않다는 점, 그리고 다른 모형 없이 동일한 모형 여러 개만으로도 Accuracy를 향상시킬 수 있다는 점에서 의의가 있다.

Result에서 엄청난 성능을 보여줬던 [1]의 Efficient Adaptive Ensembling은 EfficientNet 자체의 한계로 인해 적용 가능한 데이터셋이 한정되어 있다는 단점이 있다. 세부적으로는 input 이미지의 해상도가 8 또는 16의 배수여야 해서 이미지의 정보 손실이 일어날 수 있다. 만약 다른 해상도가 들어갈 경우 이미지의 boundary에 zero-padding이 들어가 computation resource를 많이 쓸 수밖에 없다. 그리고 CIFAR-10과 같이 resolution이 작은 이미지는 overfitting이 발생할 수 있다. tiny-MOAT ensemble 모델은 accuracy가 조금 하락했지만 위와 같은 단점이 없다. 단점을 상쇄하면서도 parameter수와 연산량은 [1]와 비슷하므로 향후 연구에서 EfficientNet을 대신하여 tiny-MOAT을 이용한 ensemble은 충분히 가치가 있을 것으로 보인다.

4.2 Discussion

본 연구에서는 GPU 할당량 제한으로 인해 앙상블 모형의 weak learner들을 2개로 진행하였다. GPU 할당량이 충분하다면 4개 이상의 sub-train set으로 각각 과적합을 시킨 weak learner들의 앙상블을 진행하여 더 좋은 결과를 낼 것으로 기대된다.

또한 [1]에서 최종 combination layer를 연결하는 구체적인 방법이 제시되어있지 않아 두 Feature extractor의 말단부를 Flatten 한 후 연결하여 한 층의 softmax activation이 적용된 output에 직접 연결하는 방식을 직접 구상하였으며, overfitting 된 weak learner들의 일반화된 성능을 위하여 combination layer에 dropout, ℓ_1 & ℓ_2 regularization 등의 다양한 방법을 시도했다. 그 결과 본문에서 사용된 방식의 combination layer가 성능이 가장 좋았으며 이후 연구에서 더 나은 방법을 찾아보고자 한다.

REFERENCES

- [1] Antonio Bruno, Davide Moroni, and Massimo Martinelli. Efficient adaptive ensembling for image classification, 2022.
- [2] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale, 2020.
- [3] Keiron O'Shea and Ryan Nash. An introduction to convolutional neural networks, 2015.
- [4] Mingxing Tan and Quoc V. Le. Efficientnet: Rethinking model scaling for convolutional neural networks. 2019.
- [5] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need, 2017.
- [6] Chenglin Yang, Siyuan Qiao, Qihang Yu, Xiaoding Yuan, Yukun Zhu, Alan Yuille, Hartwig Adam, and Liang-Chieh Chen. Moat: Alternating mobile convolution and attention brings strong vision models, 2022.

ROLE DIVISION IN THIS PAPER

A. Dong Uk Shin

- Code: Pet dataset experiment(moat ensembling), CIFAR-10 ensembling
- Report: Main Framework, PET dataset 설명
- PPT 및 발표: Main Framework

B. Kyungseon Lee

- Code: Flower dataset experiment(tiny moat와 moat ensembling 비교)
- Report: Abstract, Introduction(MOAT & Ensembling paper 설명), Flower dataset 설명
- PPT 및 발표: Introduction

C. Dayeon Jung

- Code: Data augmentation, CIFAR-10 dataset experiment (tiny moat)
- Report: Experiment (CIFAR-10 dataset & Result), Conclusion (Summary & Discussion)
- PPT 및 발표: Experiment, Conclusion